


Automatyczne wykrywanie liczby klastków w danych

Porównanie metod Elbow, Silhouette oraz Gap Statistic

Jakub Jurzak, Marcin Osojca

Przedmiot: Eksploracja i Wizualizacja Danych | Informatyka mgr.



Cel: Test skuteczności nienadzorowanych heurystyk



Problem: Nakładające się na siebie, wielowymiarowe klasy.




Zadanie: Znalezienie optymalnego k (liczby klastrów) bez dostępu do etykiet.



Ewaluacja: Zderzenie wyników heurystyk z rzeczywistością (Ground Truth).

Czy standardowe metody potrafią odnaleźć ukrytą strukturę w wysoce problematycznych danych?



Dry Bean Dataset – Trudne środowisko analityczne



13 611

Obserwacji



16

Cech numerycznych



7


Ukrytych klas
(Ground Truth)



Silne


Nakładanie cech

Rozkład klas w zbiorze Dry Bean Dataset




Niezbalansowany rozkład: Wyraźna dominacja klasy DERMASON.

Rozkłady wybranych cech wg klasy



Trudność przestrzenna: Gatunki są morfologicznie bardzo podobne. Histogramy ujawniają zatarte granice (szczególnie między Seker, Dermason i Sira).

Pipeline analityczny



Heurystyki w poszukiwaniu optymalnego k



Elbow Method (Łokieć)



Metryka:

Inercja (WCSS - Suma kwadratów odległości).



Zasada:

Poszukiwanie łokcia na wykresie – punktu, w którym spadek wariancji wewnątrz klastrów drastycznie maleje.



Silhouette Score (Sylwetka)



Metryka:

Spójność vs Separacja.



Zasada:

Szukamy absolutnego maksimum. Oblicza proporcję odległości wewnątrz własnej grupy do odległości od obcych klastrów.



Gap Statistic (Statystyka luki)



Metryka:


Oczekiwana vs Obserwowana dyspersja.




Zasada:

Porównuje inercję rzeczywistych danych z inercją dla danych wygenerowanych ze sztucznego rozkładu jednorodnego.


Werdykt: Żadna z metod nie trafiła w $k=7$



Wskazuje $k=4$ (przedwczesne wypłaszczenie).



Silnie zaniża do $k=3$ (agresywne łączenie grup w celu maksymalizacji separacji).



Daje najlepsze oszacowanie $k=5$.

Metoda	Sugerowane k	ARI	NMI
Elbow Method	4	0.4375	0.5958
Silhouette Score	3	0.2967	0.4832
Gap Statistic	5	0.5472	0.6808

Gap Statistic radzi sobie najlepiej z nakładającymi się klastrami, dostarczając najwyższe wskaźniki trafności: ARI (0.5472) i NMI (0.6808).

Wnioski – Kiedy matematyka potrzebuje eksperta



Iluzja separacji:

Tradycyjne heurystyki (szczególnie Silhouette) zawodzą przy płynnych granicach między klasami o podobnych cechach. Mają tendencję do **sztucznego zlepiania naturalnych klastrów**.



Zwycięzca eksperymentu:

Gap Statistic ($k=5$) okazał się najbardziej odporny na anomalie wynikające z silnie nakładających się zbiorów.



Rola czynnika ludzkiego:

Algorytmy nienadzorowane to tylko drogowskazy. Nawet przy zaawansowanej optymalizacji, wiedza dziedzinowa pozostaje kluczowa do ostatecznej i poprawnej interpretacji struktury danych.

