

Proposal projektu

Eksploracja i wizualizacja danych

Informacje podstawowe

Element	Opis
Temat projektu	Automatyczne wykrywanie liczby klastrów w danych – porównanie metod Elbow, Silhouette oraz Gap Statistic.
Zespół:	Jakub Jurzak, Marcin Osojca
Kierunek studiów	Informatyka mgr. dzienne 3 sem.
Data	11 marca 2026

Problem badawczy

Głównym problemem badawczym jest ocena skuteczności i wiarygodności popularnych heurystyk (metoda łokcia, Silhouette Score, Gap Statistic) w określaniu optymalnej liczby klastrów. Problem ten zostanie zbadany poprzez zastosowanie miar zarówno na wygenerowanych danych syntetycznych (różne topologie), jak i na wielowymiarowym rzeczywistym zbiorze danych o znanej liczbie klas (tzw. ground truth), co pozwoli zweryfikować użyteczność tych metod w obliczu nakładających się na siebie skupień.

Pytania badawcze

- Która z analizowanych miar (Elbow, Silhouette, Gap Statistic) najdokładniej wskaże rzeczywistą liczbę klas ($k = 7$) w wielowymiarowym zbiorze Dry Bean Dataset?
- Jak kształt, gęstość i stopień nakładania się klastrów wpływają na skuteczność poszczególnych metod oceny?
- W jakich scenariuszach (np. klastry niesferyczne, wklęsłe) miary bazujące na odległościach wewnątrz- i międzygrupowych, takie jak Silhouette Score, mają tendencję do zawodzenia?

Zbiór danych

Element	Opis
Nazwa zbioru danych	Dry Bean Dataset
Źródło danych (URL)	https://archive.ics.uci.edu/dataset/602/dry+bean+dataset
Liczba obserwacji	13 611
Liczba zmiennych	17 (16 cech numerycznych + 1 etykieta klasy)
Typ zmiennych	Numeryczne (ciągłe), Kategoryczna (nominalna)

Krótki opis danych

Zbiór "Dry Bean Dataset" zawiera informacje o 16 cechach morfologicznych oraz wymiarach wyekstrahowanych z obrazów 7 różnych zarejestrowanych gatunków fasoli. Cechy te charakteryzują się różną wariancją, a niektóre gatunki (klastry) są do siebie bardzo podobne, co tworzy wymagające środowisko analityczne. W ramach projektu algorytmy grupujące będą działać w sposób w pełni nienadzorowany (bez dostępu do etykiet), a następnie wskaźniki (Elbow, Silhouette, Gap) posłużą do oszacowania optymalnego k . Dostępna w zbiorze rzeczywista etykieta klasy (ground truth = 7) posłuży jedynie do końcowej oceny, czy metody ewaluacyjne zadziałały poprawnie.

Wstępna charakterystyka zmiennych

Zmienna	Typ	Opis
Area	Numeryczna (ciągła)	Pole powierzchni ziarna fasoli (liczba pikseli)
Perimeter	Numeryczna (ciągła)	Obwód ziarna fasoli
Compactness	Numeryczna (ciągła)	Miara zwartości kształtu (proporcja pola do obwodu)
Class	Kategoryczna	Etykieta gatunku fasoli (używana wyłącznie do walidacji)

Decyzja prowadzącego:

- Dataset zatwierdzony
- Dataset wymaga zmiany

